

מעבדה לסטטיסטיקה: מודל פואסון עם פרמטר משתנה

כזכור, X_j הוא מספר הפרגמנטים המתחילים בבסיס ה- j , $j = 1, \dots, J$, ואילו X_j משתנים מקריים המציינים לאן נפל הפרגמנט ה- j . בשבועיים החולפים הראים שהנחת האחידות לא מתארת היטב את הנתונים שלנו, ואנחנו צריכים מודל גמיש יותר. מודל הפואסון המשתנה אכן גמיש בהרבה, ומחווה את המודל הבסיסי לתופעות דיסקרטיות רבות.

מודל פואסוני לבסיס בודד

ע"פ מודל זה, מנשר להניח שכל הפרגמנטים מתפלגים אחיד (הנחה 1), ונזכיר את הסיומן

$$p_i = P(X_1 = i) = P(X_2 = i) = \dots = P(X_j = i)$$

עבור ההסתברות שפרגמנט כלשהו יתחיל בבסיס ה- i (הסתברות זהה לכל פרמנט).

כמו כן, ניחש שהפרגמנטים אינם תלויים (ההנחה כנראה איננה בדיוק נכונה, אך ניתן להאמין שהתלות קטנה). בפרט, משתני האינדיקטור $1(X_j = i)$ הינם משתני ברוג'י בלתי תלויים ושוי התפלגות, עם הסתברות הצלחה p_i . מכאן, ש $X_j = \sum_{i=1}^J 1(X_j = i)$ מתפלג בינומית:

$$X_j \sim \text{Binomial}(J, p_i),$$

ובקירוב פואסוני

$$X_j \sim \text{Poisson}(J \cdot p_i).$$

מודל פואסוני לתא

היתרון הגדול שמאפשר הקירוב הפואסוני זה שקל מאוד לחבר משתנים פואסונים בלתי תלויים.

תזכורת:

$$X_1 + Y_2 \sim \text{Poisson}(E[Y_1] + E[Y_2])$$

$$X_1 + \dots + Y_n \sim \text{Poisson}(\sum_{i=1}^n E[Y_i])$$

עבור תאים בגודל b , נסמן בעזרת \tilde{Y}_k את מספר הפרגמנטים בתא ה- k , כלומר:

$$\tilde{Y}_k = Y_{bk-b+1} + \dots + Y_{bk}$$

אם כן, מהנחת חוסר התלות:

$$\tilde{Y}_k \sim \text{Poisson}(\lambda_k), \quad \lambda_k = J \cdot (p_{bk-b+1} + \dots + p_{bk}).$$

הערות:

- בהמשך דניח את הטילדה ב- \tilde{Y}_k ונסמן במקומו Y_k , כאשר האינדקס (k) וההקשר יבהירו שמדובר בתא ולא בבסיס יחיד.

- כזכור, השונות של פואסון שווה לתוחלת. כלומר $\text{Var}(Y_k) = E[Y_k]$. בפרט, ככל

שהתוחלת גבוהה יותר גם השונות גדלה. עם זאת, כדאי לזכור שהמשמעות של המשוואה

היא שהפיזור (סטיית התקן) או ממוצע המרחקים גדלה בסדר גודל של שורש התוחלת.

- פירוק השונות: כאשר מסתכלים על השונות הנצפית בין ערכי Y_k השונים, נשים לב שישנם

שני מרכיבים לשונות ראשית. התוחלות של כל Y_k אחרת, ושנית, כל Y_k מתפלג סביב

תוחלתו. למעשה, השונות הנצפית היא סכום של שני רכיבים אלו:

$$\begin{aligned} \text{Var}[Y_k] &= E_{k \in K}[\text{Var}_{\text{Pois}}[Y_k]] + \text{Var}_{k \in K}[E_{\text{Pois}}[Y_k]] \\ &= E_{k \in K}[\lambda_k] + \text{Var}_{k \in K}[\lambda_k] = \bar{\lambda} + \frac{1}{K} \sum_{k \in K} (\lambda_k - \bar{\lambda})^2. \end{aligned}$$

כאשר $\bar{\lambda} = \frac{1}{K} \sum_{k \in K} \lambda_k$ היא התוחלת הממוצעת לתא בגודל b .

- אפילו אם p_1, \dots, p_J שונים אחד מהשני, זה לא מספיק כדי לראות הבדלים גדולים בין ה- λ_k

ות. הסיבה להבדלים הגדולים שאנחנו בין ה- λ_k היא שההסתברויות בסביבה הקרובה דומות

אחת לשנייה, ולכן לא מתבטלות כאשר נסכמים יחדיו. אם לא היה מבנה מרחבי ובאופן מקרי

היינו מאחדים תאים, רוב ההבדלים היו נעלמים.

- לפחות בשלב זה ננסה לחזות את λ_k ישירות ע"י התאמת קו גרסיה GC_k , אולם המודל

זמין גם לנסות לחזות את ה- λ_k וקים ישירות. אני מקווה שנראה עוד מזה בשבועות האחרונים

של המעבדה.